
Convolutional Neural Network (CNN)

Winter Vacation Capstone Study

TEAM Kai.Lib

발표자 : 배세영


2019.12.27 (FRI)

CNN의 등장 배경

▪ 전연결 신경망 (Fully Connected Neural Network, FCNN) 의 한계

Fully Connected Layer만으로 구성된 인공 신경망의 입력 데이터는 1차원 배열 형태로 한정된다
한 장의 컬러 사진은 RGB 값을 갖는 3차원 배열, 배치 모드에 사용되는 여러 장의 사진은 4차원 배열 형태

Image Data로 전연결 신경망을 학습시켜야 할 경우 3차원 데이터를 1차원으로 평면화 시키는 과정이 선행되어야 함
이 과정에서 공간 정보가 손실, 특징 추출과 학습이 비효율적



CNN의 등장배경

▪ 전연결 신경망 (Fully Connected Neural Network, FCNN) 의 한계

이미지의 공간 정보를 유지한 상태로 학습이 가능한 모델의 필요성이 대두되어
합성곱 신경망(Convolutional Neural Network)이 탄생

CNN은 기존의 FCNN에 대하여 다음과 같은 **차별점**을 가진다 :

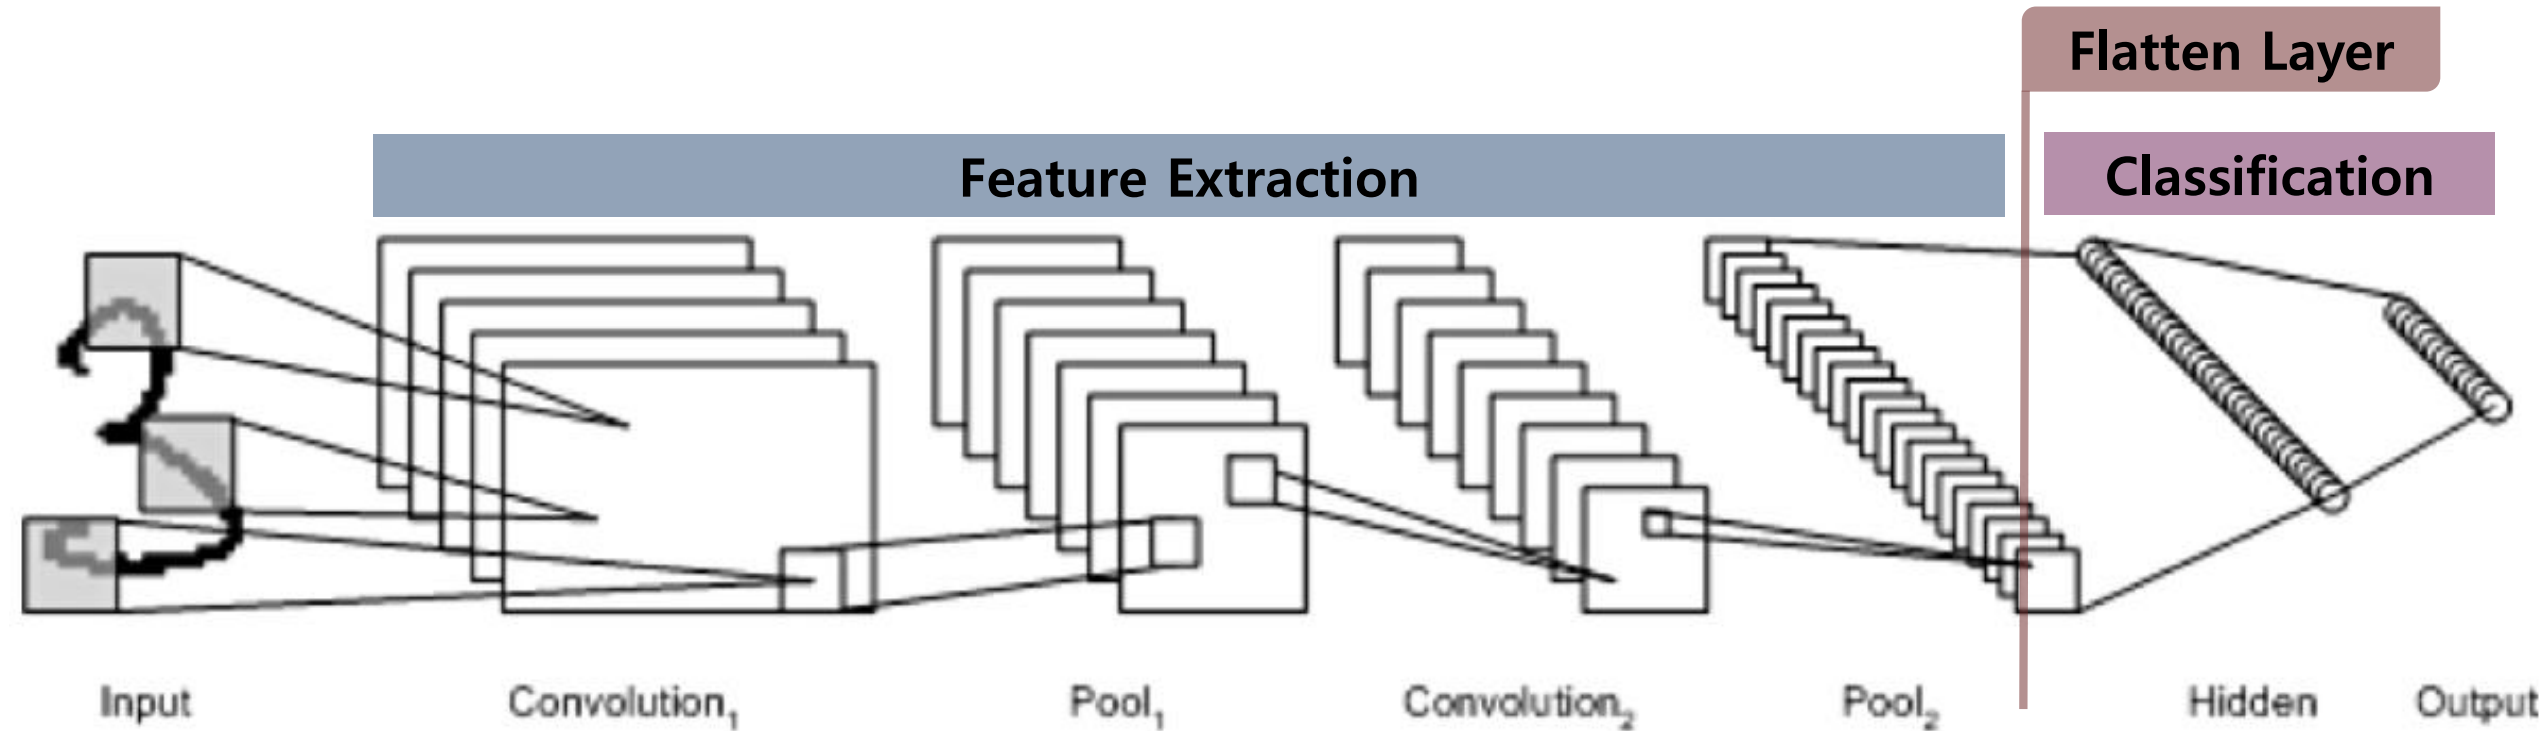
- 각 레이어의 입출력 데이터 형상 유지
- 이미지의 공간 정보를 유지하면서 인접 이미지와의 특징을 효과적으로 인식
- 복수의 필터로 이미지의 특징 추출 및 학습
- 추출한 이미지를 모으고 강화하는 Pooling Layer
- 필터를 공유 파라미터로 사용하므로, 일반 인공 신경망과 비교하여 학습 파라미터가 매우 적음

CNN의 기본 구조

특징 추출(Feature Extraction) 과 분류(Classification) 영역

특징 추출 영역 : Convolution Layer와 Pooling Layer를 겹쳐 쌓는 형태
분류 영역 : FC Layer로 구성

특징 추출 영역과 분류 영역 사이에 이미지 형태의 데이터를 배열 형태로 만드는 Flatten Layer 위치



CNN 용어 정리

- CNN에서 사용되는 주요 용어
 - 컨볼루션 (Convolution), 합성곱
 - 채널 (Channel)
 - 필터 (Filter)
 - 스트라이드 (Stride)
 - 패딩 (Padding)
 - 피쳐 맵 (Feature Map)
 - 풀링 (Pooling) 레이어

CNN 용어 정리

- CNN에서 사용되는 주요 용어
 - 컨볼루션 (Convolution), 합성곱
 - 채널 (Channel)
 - 필터 (Filter)
 - 스트라이드 (Stride)
 - 패딩 (Padding)
 - 피쳐 맵 (Feature Map)
 - 풀링 (Pooling) 레이어

1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0

Image

4		

Convolved
Feature

CNN 용어 정리

- CNN에서 사용되는 주요 용어

- 컨볼루션 (Convolution), 합성곱

- 채널 (Channel)

- 필터 (Filter)

- 스트라이드 (Stride)

- 패딩 (Padding)

- 피쳐 맵 (Feature Map)

- 풀링 (Pooling) 레이어

- 컨볼루션 레이어의 뉴런은 입력 이미지의 모든 픽셀에 연결되는 것이 아니라 뉴런의 수용영역 (Receptive Field) 안에 있는 픽셀에만 연결

- 초반의 컨볼루션 레이어에서는 저수준 특성에 집중하고, 후반에는 고수준 특성으로 조합하도록 동작

CNN 용어 정리

- CNN에서 사용되는 주요 용어

- 컨볼루션 (Convolution), 합성곱

- 채널 (Channel)

- 필터 (Filter)

- 스트라이드 (Stride)

- 패딩 (Padding)

- 피쳐 맵 (Feature Map)

- 풀링 (Pooling) 레이어

- 합성곱:

하나의 함수와 또 다른 함수를 반전 이동한 값을 곱한 다음, 구간에 대하여 적분하여 새로운 함수를 만드는 것

$$(f * g)(i, j) = \sum_{x=0}^{h-1} \sum_{y=0}^{w-1} f(x, y) g(i - x, j - y)$$

- 매우 유사한 연산으로 교차 상관(Cross-Correlation)이 있음

$$(f * g)(i, j) = \sum_{x=0}^{h-1} \sum_{y=0}^{w-1} f(x, y) g(i \oplus x, j \oplus y)$$

CNN 용어 정리


- CNN에서 사용되는 주요 용어

- 컨볼루션 (Convolution), 합성곱
- 채널 (Channel)
- 필터 (Filter)
- 스트라이드 (Stride)
- 패딩 (Padding)
- 피쳐 맵 (Feature Map)
- 풀링 (Pooling) 레이어

- 합성곱과 교차 상관의 차이는 한 함수를 반전하는지 여부의 차이 뿐
- CNN에 합성곱을 적용하려면 필터의 값을 반전시켜 연산해야 함
- CNN의 목표는 필터의 값을 학습하는 것이므로 학습 단계와 추론 단계에서 일관된 필터 값을 사용한다면 반전 여부는 중요치 않음
- 때문에 필터를 반전시키는 데 걸리는 연산량과 시간 소요를 줄이기 위하여 Tensorflow를 비롯한 다른 딥러닝 프레임워크들은 합성곱 대신 교차 상관을 사용하여 컨볼루션 레이어를 구현

CNN 용어 정리

- CNN에서 사용되는 주요 용어
 - 컨볼루션 (Convolution), 합성곱
 - 채널 (Channel)
 - **필터 (Filter)**
 - 스트라이드 (Stride)
 - 패딩 (Padding)
 - 피쳐 맵 (Feature Map)
 - 풀링 (Pooling) 레이어



CNN 용어 정리


- CNN에서 사용되는 주요 용어

- 컨볼루션 (Convolution), 합성곱
- 채널 (Channel)
- 필터 (Filter)
- 스트라이드 (Stride)
- 패딩 (Padding)
- 피쳐 맵 (Feature Map)
- 풀링 (Pooling) 레이어

- 앞서 언급했던 뉴런의 수용영역(Receptive Field)를 결정하는 것이 필터
- 커널(Kernel)이라고도 하며, 컨볼루션 레이어의 가중치 파라미터 W 에 해당
- 필터와 유사한 이미지의 영역을 강조하는 특성 맵 (Feature Map)을 출력하여 다음 레이어로 전달

CNN 용어 정리

- CNN에서 사용되는 주요 용어
 - 컨볼루션 (Convolution), 합성곱
 - 채널 (Channel)
 - 필터 (Filter)
 - 스트라이드 (Stride)
 - 패딩 (Padding)
 - 피쳐 맵 (Feature Map)
 - 풀링 (Pooling) 레이어



CNN 용어 정리

- CNN에서 사용되는 주요 용어

- 컨볼루션 (Convolution), 합성곱

- 채널 (Channel)

- 필터 (Filter)

- 스트라이드 (Stride)

- 패딩 (Padding)

- 피쳐 맵 (Feature Map)

- 풀링 (Pooling) 레이어


- 컬러 이미지는 3개 채널로 구성 (R,G,B)

- 흑백 이미지는 1개 채널

- 입력 데이터와 필터의 채널 수를 일치시켜야 함

CNN 용어 정리

- CNN에서 사용되는 주요 용어
 - 컨볼루션 (Convolution), 합성곱
 - 채널 (Channel)
 - 필터 (Filter)
 - 스트라이드 (Stride)
 - **패딩 (Padding)**
 - 피쳐 맵 (Feature Map)
 - 풀링 (Pooling) 레이어



└──────────> 1픽사리 zero- padding

CNN 용어 정리

- CNN에서 사용되는 주요 용어

- 컨볼루션 (Convolution), 합성곱
- 채널 (Channel)
- 필터 (Filter)
- 스트라이드 (Stride)
- 패딩 (Padding)
- 피쳐 맵 (Feature Map)
- 풀링 (Pooling) 레이어

- 합성곱 연산 수행 전, 입력 데이터 주변을 특정 값으로 채워 늘리는 것
- 데이터의 공간적(Spatial) 크기는 컨볼루션 레이어를 지날 때 마다 작아지므로 가장자리의 정보가 사라지는 문제 발생
- 이 문제를 해결하기 위해 출력 데이터의 공간적 크기를 조절하는 것이 목적, 주로 입력 데이터의 크기와 동일하도록 조정
- 주로 0으로 채우는 Zero-Padding 사용

CNN 용어 정리

- CNN에서 사용되는 주요 용어

- 컨볼루션 (Convolution), 합성곱

- 채널 (Channel)


- 필터 (Filter)

- **스트라이드 (Stride)**

- 패딩 (Padding)

- 피쳐 맵 (Feature Map)

- 풀링 (Pooling) 레이어



CNN 용어 정리

- CNN에서 사용되는 주요 용어

- 컨볼루션 (Convolution), 합성곱
- 채널 (Channel)
- 필터 (Filter)
- 스트라이드 (Stride)
- 패딩 (Padding)
- 피쳐 맵 (Feature Map)
- 풀링 (Pooling) 레이어

- 입력 데이터에 필터를 적용할 때 필터가 이동할 간격
- 출력 데이터의 크기 조절이 목적
- 보통 1과 같이 작은 값이 더 잘 작동하며 스트라이드가 1일 경우 입력 데이터의 공간적 크기는 풀링 레이어에서만 조절할 수 있게 됨

CNN 용어 정리

▪ CNN에서 사용되는 주요 용어

▪ 컨볼루션 (Convolution), 합성곱 *Max-pooling*

▪ 채널 (Channel)

▪ 필터 (Filter)

▪ 스트라이드 (Stride)

▪ 패딩 (Padding)

▪ 피쳐 맵 (Feature Map)

▪ 풀링 (Pooling) 레이어

1	2	1	0
0	1	2	3
3	0	1	2
2	4	0	1



2	

1	2	1	0
0	1	2	3
3	0	1	2
2	4	0	1



2	3
4	

Stride = 2

1	2	1	0
0	1	2	3
3	0	1	2
2	4	0	1



2	3

1	2	1	0
0	1	2	3
3	0	1	2
2	4	0	1



2	3
4	2

CNN 용어 정리

- CNN에서 사용되는 주요 용어

- 컨볼루션 (Convolution), 합성곱
- 채널 (Channel)
- 필터 (Filter)
- 스트라이드 (Stride)
- 패딩 (Padding)
- 피쳐 맵 (Feature Map)
- 풀링 (Pooling) 레이어

- 컨볼루션 레이어의 출력을 입력으로 받아 출력 데이터의 크기를 줄이거나 특정 데이터를 강조하기 위해 사용
- Max Pooling, Average Pooling, Min Pooling 등의 방식이 있으나 이미지 처리에서는 Max Pooling을 주로 사용

CNN 용어 정리

- CNN에서 사용되는 주요 용어

- 컨볼루션 (Convolution), 합성곱

- 채널 (Channel)

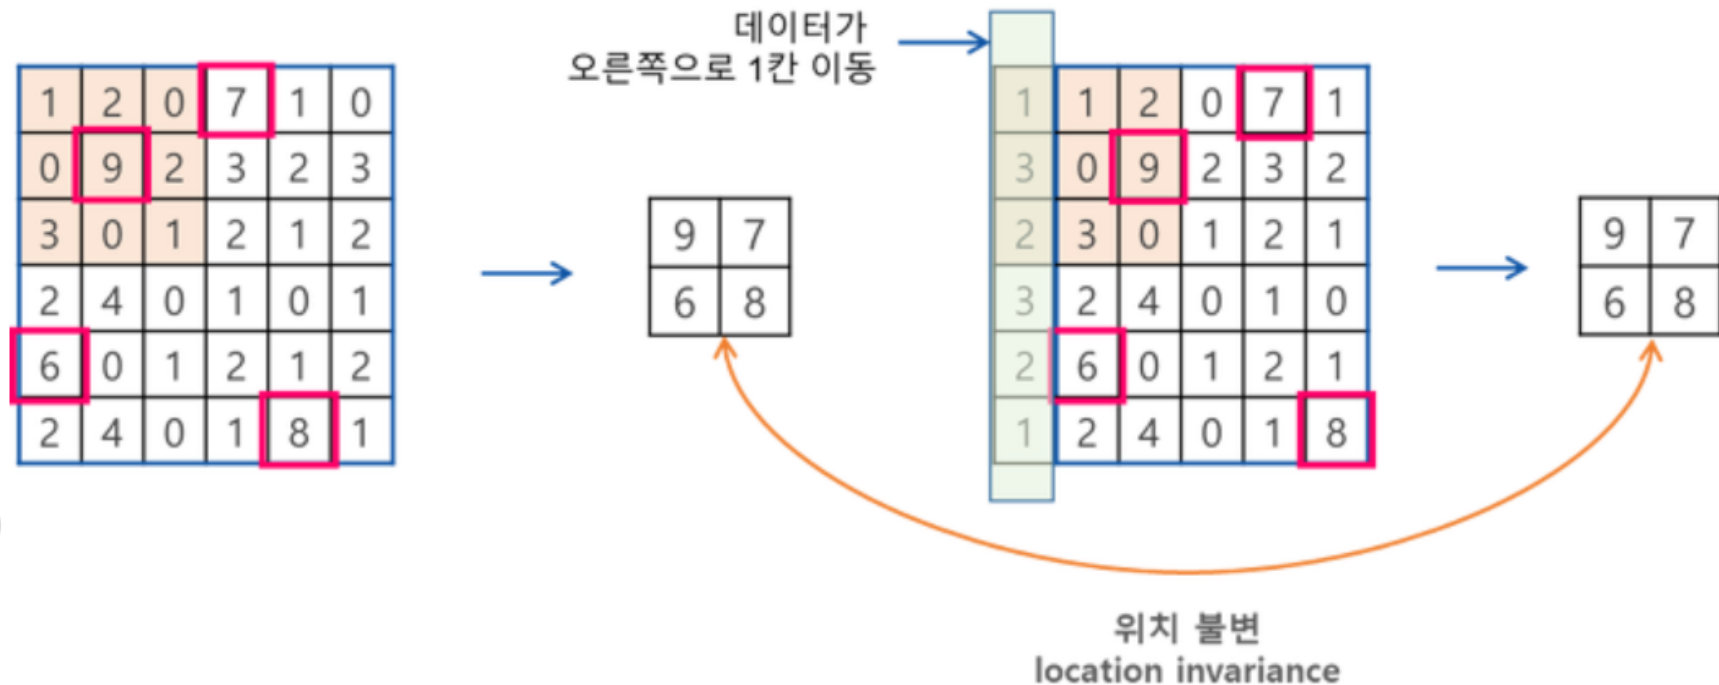
- 필터 (Filter)

- 스트라이드 (Stride)

- 패딩 (Padding)

- 피쳐 맵 (Feature Map)

- 풀링 (Pooling) 레이어



CNN 용어 정리

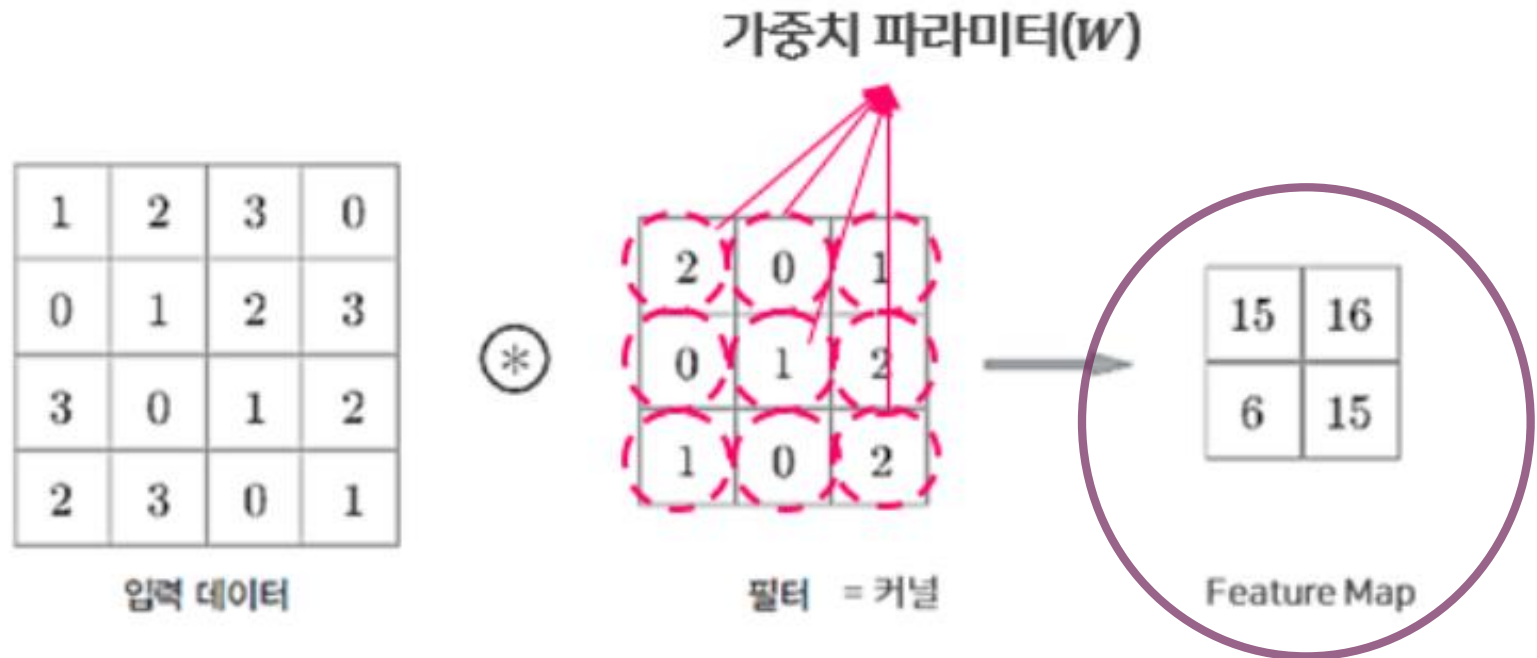
- CNN에서 사용되는 주요 용어

- 컨볼루션 (Convolution), 합성곱
- 채널 (Channel)
- 필터 (Filter)
- 스트라이드 (Stride)
- 패딩 (Padding)
- 피쳐 맵 (Feature Map)
- 풀링 (Pooling) 레이어

- 풀링을 통해 계산한 이미지의 특징은 이미지 내의 위치에 대한 변화에 영향을 덜 받음
- ex) 눈(Eye)의 특징이 이미지 우상단과 좌하단에 있는 경우
- 이처럼 풀링을 통해 찾고자 하는 특징의 불변성 (Invariance)를 발견하여 공간적 변화를 극복할 수 있음
- 물론 처리되는 데이터의 양과 모델의 전체 매개변수의 수를 줄일 수 있는 기술적인 장점도 존재

CNN 용어 정리

- CNN에서 사용되는 주요 용어
 - 컨볼루션 (Convolution), 합성곱
 - 채널 (Channel)
 - 필터 (Filter)
 - 스트라이드 (Stride)
 - 패딩 (Padding)
 - 피쳐 맵 (Feature Map)
 - 풀링 (Pooling) 레이어



CNN 용어 정리

- CNN에서 사용되는 주요 용어

- 컨볼루션 (Convolution), 합성곱
- 채널 (Channel)
- 필터 (Filter)
- 스트라이드 (Stride)
- 패딩 (Padding)
- 피쳐 맵 (Feature Map)
- 풀링 (Pooling) 레이어

- CNN에서는 입력 데이터와 출력 데이터의 형상이 동일하게 유지됨
- 특성 맵(Feature Map)은 레이어의 출력 데이터
- 활성화 맵(Activation Map)이라고도 지칭
- 필터의 가중치 값을 기준으로 연산하여 필터와 유사한 이미지의 영역이 강조된 형태

CNN 레이어 출력 크기 계산

▪ 출력 크기 계산법

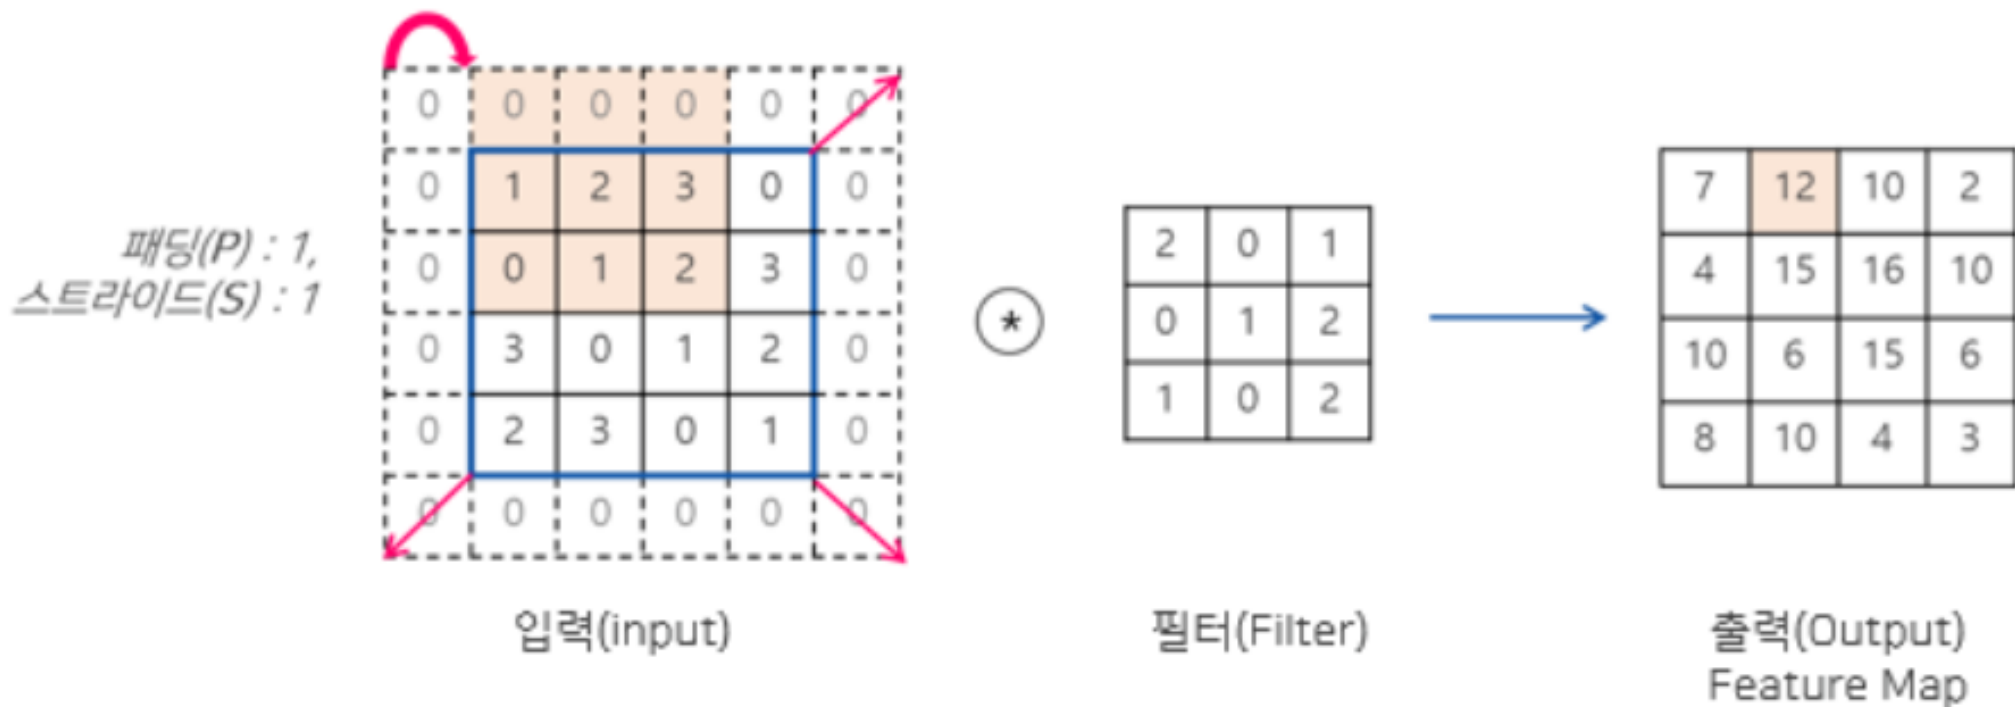
패딩과 스트라이드를 적용하고, 입력 데이터와 필터의 크기가 주어졌을 때 출력 데이터의 크기를 구하는 식

$$(OH, OW) = \left(\frac{H + 2P - FH}{S} + 1, \frac{W + 2P - FW}{S} + 1 \right)$$

- (H, W) : 입력 데이터의 Height, Width Size
- (FH, FW) : 필터의 Height, Width Size
- S : 스트라이드 (Stride)
- P : 패딩 (Padding)
- (OH, OW) : 출력 데이터의 Height, Width Size

CNN 레이어 출력 크기 계산

- 출력 크기 계산법




$$(OH, OW) = \left(\frac{4 + 2 \times 1 - 3}{1} + 1, \frac{4 + 2 \times 1 - 3}{1} + 1 \right) = (4, 4)$$

3차원 데이터에 대한 CNN

3차원 합성곱 연산

입출력 데이터를 직육면체의 블록으로 생각하면 이해하기 편함
3차원 데이터는 (Height, Width, Channel) 순으로 표현

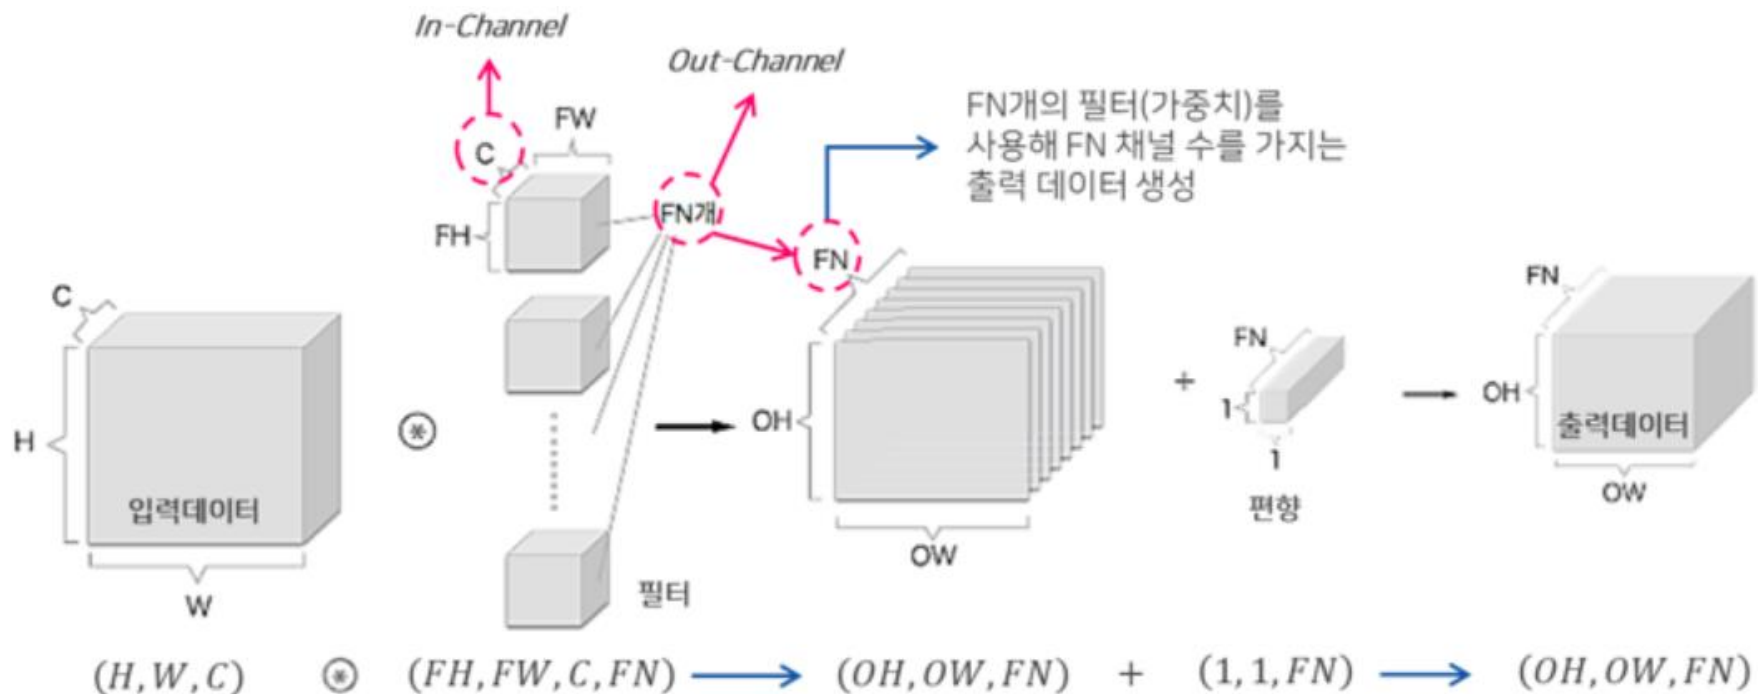


3차원 입력 데이터에 대하여 하나의 필터로 합성곱 연산을 수행하면 하나의 채널을 가지는 특성 맵이 출력

3차원 데이터에 대한 CNN

3차원 합성곱 연산

여러 개의 채널을 갖는 특성 맵을 출력하기 위해서는 여러 개의 필터를 사용해야 함

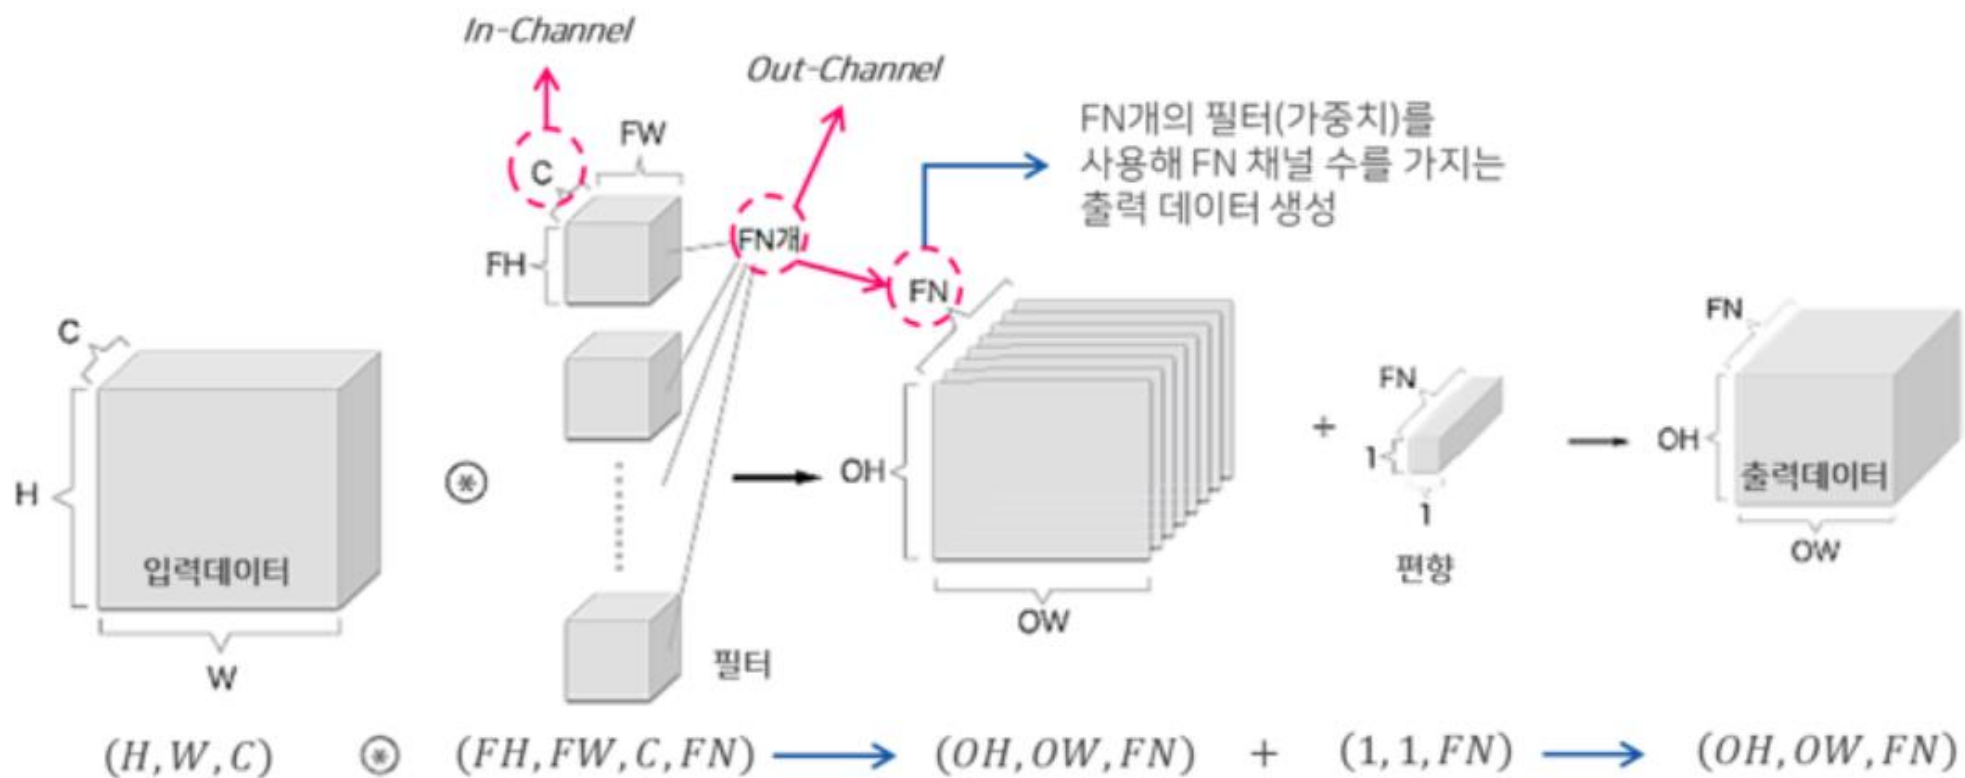


컨볼루션 레이어의 학습 파라미터 수 : $C \times FH \times FW \times FN$

3차원 데이터에 대한 CNN

3차원 합성곱 연산


여러 개의 채널을 갖는 특성 맵을 출력하기 위해서는 여러 개의 필터를 사용해야 함



3차원 데이터에 대한 CNN

▪ 수식으로 나타내기

컨볼루션 레이어 층에 있는 j 개의 특성맵 행 열에 위치한 뉴런은 이전 층의 1 층에 있는 모든 특성맵에서 $i \times S_h$ 에서부터 $i \times S_h + f_h - 1$ 까지의 행과 $j \times S_w$ 에서부터 $j \times S_w + f_w - 1$ 까지의 열에 있는 뉴런의 출력에 연결된다.



S_h, S_w : 높이(h), 너비(w)의 스트라이드
 f_h, f_w : 필터의 높이(h)와 너비(w)

3차원 데이터에 대한 CNN

▪ 수식으로 나타내기

입력에 대한 가중치 합 (합성곱)

$$z_{i,j,k} = \underbrace{b_k}_{\text{편향 (Bias)}} + \sum_{u=0}^{f_h-1} \sum_{v=0}^{f_w-1} \sum_{k'=0}^{f_{n'}-1} x_{i',j',k'} \cdot w_{u,v,k',k} \quad \text{with} \begin{cases} i' = i \times s_h + u \\ j' = j \times s_w + v \end{cases}$$


- $z_{i,j,k}$: 합성곱층(l 층)의 k -특성 맵에서 i 행, j 열에 위치한 뉴런의 출력
- s_h, s_w : 높이(h), 너비(w)의 스트라이드
- f_h, f_w : 필터(receptive field)의 높이(h)와 너비(w)
- $f_{n'}$: 이전 층 ($l-1$)에 있는 특성맵의 수
- $x_{i',j',k'}$: $l-1$ 층의 i' 행, j' 열, k' 특성맵에 있는 뉴런의 출력
- b_k : k -특성맵의 편향(bias) → 이 편향을 k -특성맵의 전체 밝기를 조절하는 것으로 볼 수 있음
- $w_{u,v,k',k}$: l 층의 k -특성맵에 있는 필터와 연관된 u 행, v 열, k' 특성맵의 뉴런의 가중치

CNN과 FCNN의 비교

▪ 학습 파라미터 수의 관점에서 비교

1. CNN

4개의 컨볼루션 레이어, 39x31x1 크기의 입력 데이터, 100개의 클래스로 분류



CNN과 FCNN의 비교

▪ 학습 파라미터 수의 관점에서 비교

1. CNN

4개의 컨볼루션 레이어, 39x31x1 크기의 입력 데이터, 100개의 클래스로 분류

layer	input channel	Filter	output channel	Stride	Pooling	활성함 수	Input Shape	Output Shape	파라미터 수
Convolution Layer 1	1	(4, 4)	20	1	X	relu	(39, 31, 1)	(36, 28, 20)	320
Max Pooling Layer 1	20	X	20	2	(2, 2)	X	(36, 28, 20)	(18, 14, 20)	0
Convolution Layer 2	20	(3, 3)	40	1	X	relu	(18, 14, 20)	(16, 12, 40)	7,200
Max Pooling Layer 2	40	X	40	2	(2,2)	X	(16, 12, 40)	(8, 6, 40)	0
Convolution Layer 3	40	(2, 2)	60	1	1	relu	(8, 6, 40)	(6, 4, 60)	21,600

Max Pooling Layer 3	60	X	60	(2, 2)	60	X	(6, 4, 60)	(3, 2, 60)	0
Convolution Layer 4	60	(2, 2)	80	1	1	relu	(3, 2, 60)	(2, 1, 80)	19,200
Flatten	X	X	X	X	X	X	(2, 1, 80)	(160, 1)	0
fully connected Layer	X	X	X	X	X	softmax	(160, 1)	(100, 1)	160,000
합계	X	X	X	X	X	softmax	(160, 1)	(100, 1)	208,320

컨볼루션 레이어의 학습 파라미터 수 : $C \times FH \times FW \times FN$


CNN과 FCNN의 비교

- 학습 파라미터 수의 관점에서 비교

2. FCNN

4개의 은닉층(Hidden Layer), 1209x1(39x31x1) 크기의 입력 데이터, 100개의 클래스로 분류

Input layer	Layer 1	Layer 2	Layer 3	Layer 4	Output Layer
(1209, 1)	(600, 1)	(300, 1)	(300, 1)	(150, 1)	(100, 1)



<http://taewan.kim>

CNN과 FCNN의 비교

- 학습 파라미터 수의 관점에서 비교

2. FCNN

4개의 은닉층(Hidden Layer), 1209x1(39x31x1) 크기의 입력 데이터, 100개의 클래스로 분류

레이어	입력 노드	출력 노드	Weight Shape	파라미터 수
Layer 1	1209	600	(1209,600)	725,400
Layer 2	600	300	(600,300)	180,000
Layer 3	300	300	(300,300)	90,000
Layer 4	300	150	(300,150)	45,000
Output	150	100	(150,100)	15,000
합계				1,055,400

CNN과 FCNN의 비교

- 학습 파라미터 수의 관점에서 비교
 - FCNN의 총 파라미터는 100만 개가 넘어감
 - CNN의 경우 20만개로 5배 이상의 차이
 - 은닉층이 깊어질 경우 이 차이는 더 급격히 늘어남

때문에 CNN은 FCNN과 비교하여 학습이 쉽고, 네트워크 처리 속도가 빠름