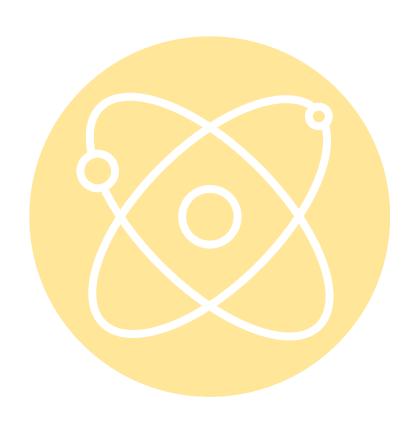
Deep Learning Study

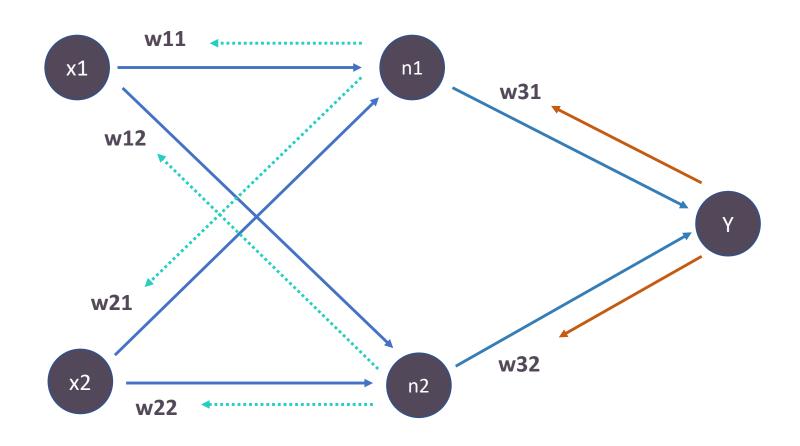
오차 역전파

KAIG

INDEX

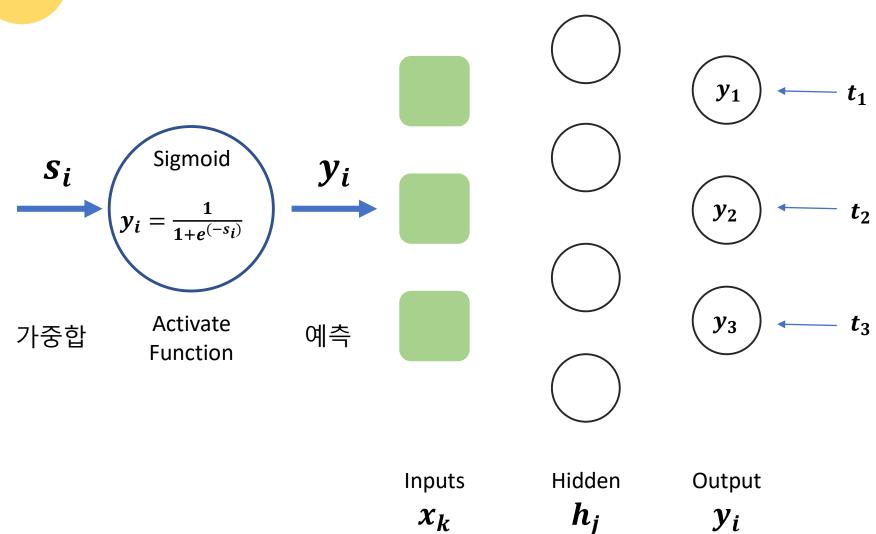


- 1 오차역전파
- 2 Android 적용



1

오차역전파



Error function, E

$$\mathbf{E} = -\sum_{i=1}^{nout} \{t_i \log(y_i) + (1 - t_i) \log(1 - y_i)\}$$

where,
$$y_i = \frac{1}{1+e^{(-s_i)}}$$
 , $s_i = \sum_{j=1} w_{ji} h_j$

$$ex$$
) $t_i = 1$ and $x_i = 0 \sim E = \infty$

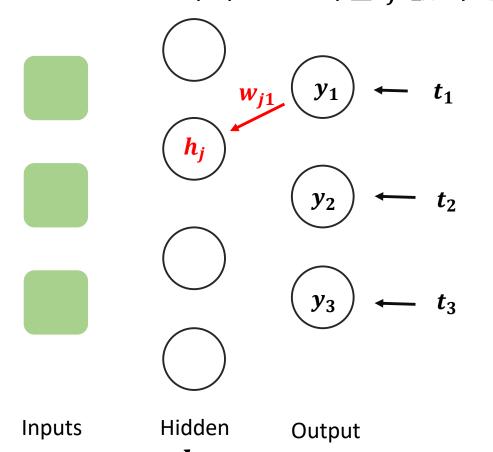
$$ex)$$
 $t_i = 1$ and $x_i = 1 \sim E = 0$

 t_i : 실제 클래스의 값 / x_i : 예상된 값

목표: 오차 E를 최소로 줄이는 것

 $\boldsymbol{x_k}$

Gradient $\rightarrow f$ 의 임의의 점 x 에서 Δx 만큼 움직였을 때, 벡터로 표시된 f값이 변화하는 값



Input Data가 아닌, Weight값을 조정함으로써 목표 t(target)값에 이르게 함

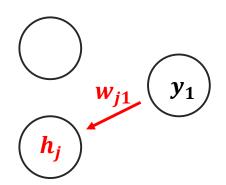
1.layer의 weight에 대한 E의 gradient를 계산하고 (E의 미분)

2. 변화량을 w의 반대 방향으로 더해준다 (-1을 곱해줌)

신경망 학습 순서를 정리해보자!

- 1. Input Layer를 지나며 weight를 곱하고
- 2. Activate function을 지난 다음
- 3. 마지막 output layer에서 오차 값을 계산하고
- 4. 업데이트를 위해 순차적으로 거꾸로 돌아간다.
- → 따라서, 돌아갈 때는 Output -> Hidden 의 weight부터 구해준다.

체인 룰



$$\frac{\partial E}{\partial w_{ji}} = \frac{\partial E}{\partial y_i} \frac{\partial y_i}{\partial s_i} \frac{\partial s_i}{\partial w_{ji}}$$

i번째 output인 y_i 에 대한 오차값에 대해 w_{ii} 가 바뀌어야 하는 정도

$$\frac{\partial E}{\partial w_{ji}} = \frac{\partial E}{\partial y_i} \frac{\partial y_i}{\partial s_i} \frac{\partial s_i}{\partial w_{ji}}$$

$$y_1 \leftarrow t_1 \quad \underline{E(x_1)}$$

$$y_2 \leftarrow t_2 E(x_2)$$

$$y_3 \leftarrow t_3 E(x_3)$$

$$\mathbf{E} = -\sum_{i=1}^{nout} \{t_i \log(y_i) + (1 - t_i) \log(1 - y_i)\}$$

$$\frac{\partial E}{\partial w_{ji}} = \frac{\partial E}{\partial y_i} \frac{\partial y_i}{\partial s_i} \frac{\partial s_i}{\partial w_{ji}}$$

$$\frac{d}{dx}y_i = \frac{d}{dx}\left[\frac{1}{1+e^{-x}}\right]$$

2 =
$$-(1 + e^{-x})^{-2}(-e^{-x})$$

$$= \left(1 + \frac{-1}{1 + e^{-x}}\right) \cdot \frac{1}{1 + e^{-x}}$$
$$= y_i \cdot (1 - y_i) \cdot \cdots \cdot b$$

Sigmoid
$$y_i = \frac{1}{1 + e^{(-s_i)}}$$

Activate Function

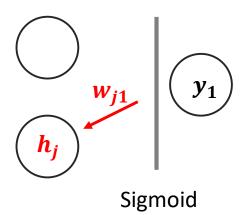
$$y_i = rac{1}{1+e^{(-s_i+b)}}$$
 , $s_i = \sum_{j=1} w_{ji} x_j$

$$\frac{\partial E}{\partial w_{ji}} = \frac{\partial E}{\partial y_i} \frac{\partial y_i}{\partial s_i} \frac{\partial s_i}{\partial w_{ji}}$$

$$s_i = \sum_{j=1}^{\infty} w_{ji} h_j$$

$$\frac{\partial s_i}{\partial w_{ji}} = \frac{\sum_{j=1} w_{ji} h_j}{\partial w_{ji}}$$

$$= h_j \cdots c$$



$$\frac{\partial E}{\partial w_{ji}} = \frac{\partial E}{\partial y_i} \frac{\partial y_i}{\partial s_i} \frac{\partial s_i}{\partial w_{ji}} = a \cdot b \cdot c$$

$$\frac{\partial E}{\partial y_i} = \frac{y_i - t_i}{y_i(1 - y_i)} \cdots a$$

$$\frac{\partial y_i}{\partial s_i} = y_i \cdot (1 - y_i) \cdots b$$

$$\frac{\partial s_i}{\partial w_{ji}} = h_j \cdots \cdots c$$

$$\frac{\partial E}{\partial w_{ji}} = (y_i - t_i)h_j$$

출력층의 가중치 업데이트

$$y_i = \frac{1}{1 + e^{(-s_i)}}$$

$$s_i = \sum_{j=1}^{\infty} w_{ji} h_j$$

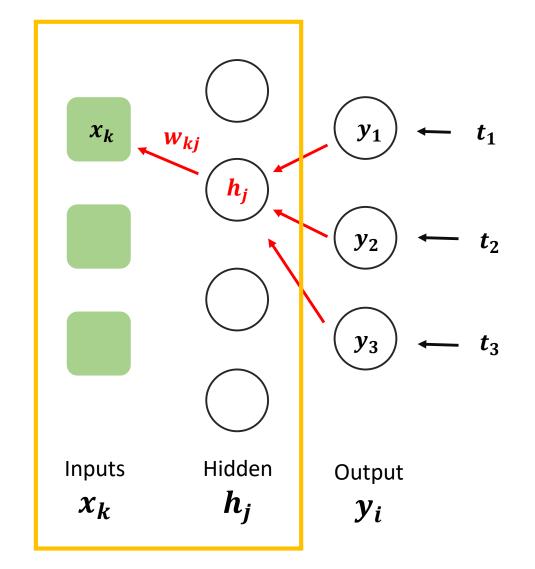
$$\frac{\partial E}{\partial w_{ji}} = (y_i - t_i)h_j$$

$$w_{ji}(T+1) = w_{ji}(T) - (y_i - t_i)h_j$$
 δy (델타식 y)

출력층의 가중치 업데이트

1

오차역전파



$$\frac{\partial E}{\partial w_{kj}} = \frac{\partial E}{\partial s_j} \frac{\partial s_j}{\partial w_{kj}}$$

$$\frac{\partial E}{\partial y_i} = \frac{y_i - t_i}{y_i(1 - y_i)} \cdots a$$

$$\frac{\partial y_i}{\partial s_i} = y_i \cdot (1 - y_i) \cdots b$$

$$(y_i-t_i)$$

은닉층의 가중치 업데이트

$$\frac{\partial E}{\partial w_{kj}} = \frac{\partial E}{\partial s_j} \frac{\partial s_j}{\partial w_{kj}}$$

$$\frac{\partial E}{\partial h_j} = \frac{\partial E}{\partial y_i} \frac{\partial y_i}{\partial s_i} \frac{\partial s_i}{\partial h_j} \qquad \qquad \left(\frac{\partial E}{\partial y_i}\right) = \frac{y_i - t_i}{y_i (1 - y_i)} \cdots a$$

$$= \sum_{i=1}^{\infty} \frac{\partial E}{\partial y_j} y_i (1 - y_j) w_{ji} \qquad \left(\frac{\partial y_i}{\partial s_i}\right) = y_i \cdot (1 - y_i) \cdots b$$

은닉층의 가중치 업데이트

$$\frac{\partial E}{\partial w_{kj}} = \frac{\partial E}{\partial s_j} \frac{\partial s_j}{\partial w_{kj}}$$

$$\frac{\partial E}{\partial w_{kj}} = \frac{\partial E}{\partial s_j} \frac{\partial s_j}{\partial w_{kj}} = \sum_{i=1}^{nout} (y_i - t_i)(w_{ji})(h_j(1 - h_j))(x_k)$$

은닉층의 가중치 업데이트

General Multiplayer Network

각 layer의 $\frac{\partial E}{\partial w_{ij}}$ 를 구하고 싶을 때,

1. 먼저 $\frac{\partial E}{\partial s_i}$ 를 계산한다.

$$2. \frac{\partial s_j}{\partial w_{kj}} = x_k$$
를 1번에 곱해준다.

→ 즉, 델타식을 먼저 구하고 나면 output의 델타식으로 다시 변환 가능하다.

new Output: $w_{31}(T+1) = w_{31}(T) - \delta y \cdot h_1$

new Hidden: $w_{11}(T + 1) = w_{11}(T) - \delta h \cdot x_1$